

tarea teorica, Juan Pablo Cabeza

PJ: Consideremos un vector bidimensional con sus dos comp. ortogonales, independientes y con distribución normal.

$$\text{Sea } U = (U_1, \dots, U_n) \text{ con } U_i \sim N(0, \sigma^2)$$

$$W = (W_1, \dots, W_n) \text{ con } W_i \sim N(0, \sigma^2)$$

en base a estos MAS, se obtiene $X = (X_1, \dots, X_n)$ dado por

$$X_i = \sqrt{U_i^2 + W_i^2}$$

obs: $U_i \sim N(0, \sigma^2)$
 $\Rightarrow U_i^2 \sim \chi^2(1)$
de ahí se distribuyen

2) Función densidad de X_i , $i=1, \dots, n$.

Notemos que, si $X_i = \sqrt{U_i^2 + W_i^2}$, entonces,

$$F_{X_i}(z) = P(X_i \leq z) = P(\sqrt{U_i^2 + W_i^2} \leq z) = P(U_i^2 + W_i^2 \leq z^2)$$

$$= \iint_{x^2 + y^2 \leq z^2} \frac{1}{2\pi\sigma^2} \exp\left(-\frac{(x^2 + y^2)}{2\sigma^2}\right) dx dy$$

tomando $x = r \cos \theta$, $y = r \sin \theta$, $r > 0$, $\theta \in [0, 2\pi)$, se suple de los teoremas de cambio de variable,

$$F_{X_i}(z) = \int_0^{2\pi} \int_0^z \frac{1}{2\pi\sigma^2} \exp\left(-\frac{r^2}{2\sigma^2}\right) r dr d\theta$$

$$= \int_0^z \frac{1}{\sigma^2} \exp\left(-\frac{r^2}{2\sigma^2}\right) r dr = \int_0^z \frac{1}{\sigma^2} \left(-\frac{\sigma^2}{r} \frac{d}{dr} \exp\left(-\frac{r^2}{2\sigma^2}\right) \right) r dr$$

$$= -\left(\exp\left(-\frac{z^2}{2\sigma^2}\right) - 1 \right) = 1 - \exp\left(-\frac{z^2}{2\sigma^2}\right)$$

Por lo tanto, $F_{X_1}(z^2) = 1 - e^{-\frac{z^2}{2\sigma^2}}$, luego,
 $\Rightarrow F_X(z) = 1 - \exp\left(-\frac{z^2}{2\sigma^2}\right)$

$\Rightarrow f(z) = \frac{d}{dz} \left(1 - e^{-\frac{z^2}{2\sigma^2}} \right) = -e^{-\frac{z^2}{2\sigma^2}} \left(-\frac{1}{\sigma^2} \right)$

es decir,

$$f(z) = \begin{cases} \frac{1}{\sigma^2} e^{-\frac{z^2}{2\sigma^2}} & , 0 \leq z < \infty \\ 0 & , \text{eoc} \end{cases}$$

P1.

b) Calculamos el estimador máxima verosimilitud ($\hat{\sigma}_{EMV}^2$) de σ^2 .

Sea $L(z_1, \dots, z_n | \sigma^2) = \prod_{i=1}^n f(z_i | \sigma^2)$

$$= \prod_{i=1}^n \left(\frac{1}{\sigma^2} e^{-\frac{z_i^2}{2\sigma^2}} \right) = \frac{1}{(\sigma^2)^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n z_i^2\right)$$

tomando \log ,

$\ln(L(z_1, \dots, z_n | \sigma^2)) = -n \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n z_i^2$

dado que buscamos $\hat{\sigma}_{EMV}^2$, debemos maximizar la función,

$$\frac{\partial}{\partial \sigma^2} \ln(L(z_1, \dots, z_n | \sigma^2)) = 0$$

$$\Rightarrow -n \frac{1}{\sigma^2} \cdot 2 - \frac{1}{2} \left(\frac{-1}{(\sigma^2)^2} \cdot \sum_{i=1}^n z_i^2 \right) = 0$$

$$\Rightarrow \frac{n}{\sigma^2} = \frac{1}{2} \sum_{i=1}^n z_i^2 \cdot \frac{1}{(\sigma^2)^2} \Rightarrow n = \frac{1}{2\sigma^2} \sum_{i=1}^n z_i^2 \Rightarrow \frac{2n}{\sum_{i=1}^n z_i^2} = \frac{1}{\sigma^2}$$

$$\Rightarrow \hat{\sigma}^2 = \frac{\sum_{i=1}^n z_i^2}{2n}$$

$$\Rightarrow \boxed{\hat{\sigma}^2 = \frac{1}{2} \left(\frac{1}{n} \sum_{i=1}^n z_i^2 \right)}$$

21.6) Veremos que $\hat{\sigma}_{EMV}^2$ es insesgado para σ^2 y calculamos la variancia de $\hat{\sigma}_{EMV}^2$.

Antes que, usando la función gamma, (solo para ahorrar cálculos, también se puede integrar por partes)

$$\begin{aligned} E(z) &= \int_0^{\infty} \frac{z}{2\sigma^2} \exp\left(-\frac{z}{2\sigma^2}\right) dz \\ &= 2\sigma^2 \int_0^{\infty} \left(\frac{z}{2\sigma^2}\right)^{2-1} \exp\left(-\frac{z}{2\sigma^2}\right) \frac{dz}{2\sigma^2} = 2\sigma^2 \Gamma(2) = 2\sigma^2 \end{aligned}$$

Luego, $E(\hat{\sigma}_{EMV}^2) = E\left(\frac{1}{2n}(z_1 + z_2 + \dots + z_n)\right)$ de la linealidad de E

$$\begin{aligned} &= \frac{1}{2n} (E(z_1) + \dots + E(z_n)) \\ &= \frac{1}{2n} (2\sigma^2 + \dots + 2\sigma^2) = \frac{2n\sigma^2}{2n} = \sigma^2 \end{aligned}$$

Por lo tanto $\hat{\sigma}_{EMV}^2$ es insesgado,

Por otra parte,

$$\begin{aligned} E(z^2) &= \int_0^{\infty} \frac{z^2}{2\sigma^2} \exp\left(-\frac{z}{2\sigma^2}\right) dz = (2\sigma^2)^2 \int_0^{\infty} \left(\frac{z}{2\sigma^2}\right)^{3-1} \exp\left(-\frac{z}{2\sigma^2}\right) \frac{dz}{2\sigma^2} \\ &= 4\sigma^4 \Gamma(3) = 4\sigma^4 2! = 8\sigma^4 \end{aligned}$$

Por lo tanto,

$$V(z) = E(z^2) - (E(z))^2 = 8\sigma^4 - (2\sigma^2)^2 = 8\sigma^4 - 4\sigma^4 = 4\sigma^4$$

Luego, $V(\hat{\sigma}_{EMV}^2) = V\left(\frac{z_1 + \dots + z_n}{2n}\right) = \frac{1}{4n^2} (V(z_1) + \dots + V(z_n))$

$$= \frac{1}{4n^2} (4\sigma^4 + \dots + 4\sigma^4) = \frac{4n\sigma^4}{4n^2} = \frac{\sigma^4}{n}$$

PS

(Bonus) Notemos que,

$$\frac{\partial^2}{\partial^2 \sigma^2} \ln(L(z_1, \dots, z_n | \sigma^2)) = -n \left(\frac{-1}{\sigma^2} \right) + \frac{1}{2} \left(\frac{-2}{(\sigma^2)^3} \right) \sum_{i=1}^n z_i$$

entonces, $E \left[\frac{\partial^2 \ln L(z_1, \dots, z_n | \sigma^2)}{\partial^2 \sigma^2} \right] = E \left[\frac{n}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \sum_{i=1}^n z_i \right]$

$$= \frac{n}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} (E(z_1) + \dots + E(z_n)) = \frac{n}{(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} (2\sigma^2 + \dots + 2\sigma^2)$$

$$= \frac{n}{(\sigma^2)^2} - \frac{2\sigma^2 n}{(\sigma^2)^3} = \frac{n}{(\sigma^2)^2} - \frac{2n}{(\sigma^2)^2} = -\frac{n}{(\sigma^2)^2}$$

Luego $I(\sigma^2) = -E \left(\frac{\partial^2 \log L(\sim)}{\partial^2 \sigma^2} \right) = \frac{n}{(\sigma^2)^2}$

Ahora, calculamos $I(\sigma^2)^{-1}$. Note que $\gamma = \frac{n}{(\sigma^2)^2} \Rightarrow (\sigma^2)^2 = \frac{n}{\gamma}$

por lo tanto $I(\sigma^2)^{-1} = \sqrt{\frac{n}{\gamma}}$. $\Rightarrow \sigma^2 = \sqrt{\frac{n}{\gamma}}$

Se sigue que, $\sqrt{n} (\sigma_{EMV}^{2(n)} - \sigma^2) \sim N(0, \sqrt{\frac{n}{\gamma}})$

Finalmente, $(\sigma_{EMV}^{2(n)} - \sigma^2) \sim N(0, \frac{1}{\sigma} \frac{1}{\sqrt{n}})$

P2. b) Sea $y = \alpha_0 + \alpha_1 x_1 + \alpha_2 x_2 + \varepsilon$, con $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$

y $D = \{x_1^{(i)}, x_2^{(i)}, y^{(i)}\}_{i=1}^n$, el conj. de datos de entrenamiento.

Notemos que la densidad conjunta de $\varepsilon_i \sim N(0, \sigma^2)$ es

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\varepsilon_i^2}{2\sigma^2}\right) = \frac{1}{\sqrt{(2\pi\sigma^2)^n}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n \varepsilon_i^2\right)$$

Determinemos el estimador máxima verosimilitud, es decir,

$$L(\alpha_i, (y_i, x_i)) = \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y - (\alpha_0 + \alpha_1 x_1 + \alpha_2 x_2))^2\right)$$

$$\Rightarrow \ln L(\alpha_i, (y_i, x_i)) = -\frac{n}{2} (\ln(2\pi) + \ln \sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y - (\alpha_0 + \alpha_1 x_1 + \alpha_2 x_2))^2$$

Por tanto, maximizar la función de verosimilitud es equivalente a minimizar,

$$\sum_{i=1}^n (y - (\alpha_0 + \alpha_1 x_1 + \alpha_2 x_2))^2$$

es decir, encontrar el estimador de máxima verosimilitud de la \log , es equivalente a minimizar el error cuadrático,

P2.d) Considere el funcional

$$J_{\text{reg}}(y, \theta) = \frac{1}{2} \|y - X\theta\|_2^2 + \frac{1}{2} \rho \|\theta\|_2^2$$

Recordemos que si $U \subset \mathbb{R}^n$ es un subconjunto y $f: U \rightarrow \mathbb{R}$ es diferenciable entonces ∇f es una función de U a \mathbb{R}^n tal que,

$$\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - \nabla f(x) \cdot h|}{\|h\|} = 0$$

Notemos que,

$$\begin{aligned} J_{\text{reg}}(y, \theta) &= \frac{1}{2} (y - X\theta)^T (y - X\theta) + \frac{1}{2} \rho \theta^T \theta \\ &= \frac{1}{2} (y^T y - y^T X\theta - \theta^T X^T y + \theta^T X^T X\theta + \rho \theta^T \theta) \end{aligned}$$

Desigñe por,

$$\begin{aligned} J_{\text{reg}}(y, \theta+h) &= \frac{1}{2} \left(y^T y - y^T X(\theta+h) - (\theta+h)^T X^T y + (\theta+h)^T X^T X(\theta+h) \right. \\ &\quad \left. + \rho(\theta+h)^T (\theta+h) \right) \\ &= J_{\text{reg}}(y, \theta) + \frac{1}{2} \left(-y^T Xh - h^T X^T y + \theta^T X^T Xh + h^T X^T X\theta + h^T X^T X\theta \right. \\ &\quad \left. + \rho(\theta^T h + h^T \theta + h^T h) \right) \end{aligned}$$

$$\Rightarrow J_{\text{reg}}(y, \theta+h) - J_{\text{reg}}(y, \theta) = \frac{1}{2} \left(-y^T X - (X^T y)^T + \theta^T X^T X + h^T X^T X + (X^T X\theta)^T + \rho\theta^T + \rho\theta^T + \rho h^T \right) \cdot h$$

De donde concluimos que el gradiente es,

$$\begin{aligned} \nabla_{\theta} J_{\text{reg}}(y, \theta) &= \theta^T X^T X - y^T X + \rho \theta^T \\ &= (\theta^T X^T - y^T) X + \rho \theta^T \end{aligned}$$

P2.d) Sea $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$

Determinemos $IP(y | x_1, x_2)$

Pdó que $\varepsilon_i \sim N(0, \sigma^2)$, entonces la densidad es

$$f(\varepsilon_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\varepsilon_i^2}{2\sigma^2}\right)$$

la cual implica que,

$$IP(y | x_1, x_2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \beta_0 - \beta_1 x_1 - \beta_2 x_2)^2}{2\sigma^2}\right)$$

P3) La estimación de cada creativo es $N(\mu, \sigma_i), i \in \{1, \dots, 17\}$
 entonces

$$f(A, \dots, G) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma_A \dots \sigma_G} \exp\left(-\frac{1}{2\sigma_A^2} (-27,000 - \mu)^2\right) \dots \exp\left(-\frac{1}{2\sigma_G^2} (-12,056 - \mu)^2\right)$$

$$\frac{\partial \ln}{\partial \mu} (P(A, \dots, G; \mu, \sigma_i)) = \frac{1}{\sigma^2} (29,2430 - 7\mu)$$

luego sumando, obtenemos

$$\mu \approx 3,4632$$